Tách quyết định sư phạm khỏi mô hình ngôn ngữ: gia sư Toán Socratic với truy xuất lai theo đồ thị tri thức

Decoupling Pedagogical Decisions from the Language Model: a Socratic Grade-5 Mathematics Tutor with Graph-Constrained Hybrid Retrieval and a Replayable Learner Model

Tác giả:	Dương Minh Vương
Chuyên ngành:	Kỹ thuật Máy tính
Email:	ougvn.it2@gmail.com
Người hướng dẫn:	ThS. Đỗ Ngọc Minh
Người đồng hướng dẫn:	PGS. TS. Đinh Triều Dương

Bản thảo, tháng 10 năm 2026

Tóm tắt. Gia sư dùng mô hình ngôn ngữ lớn (LLM) hứa hẹn dạy kèm từng học sinh ở quy mô lớn. Các "chế độ học" hiện nay chỉ nhắc mô hình dạy theo phương pháp Socratic, nên chính mô hình vẫn quyết định khi nào gợi ý, khi nào nói đáp án và khi nào coi một câu trả lời là đúng; hành vi này không được bảo đảm trước một đứa trẻ khăng khăng hoặc nhờ làm hộ. Chúng tôi tách quyết định khỏi diễn đạt: chính sách tất định chọn nước đi và bậc gợi ý, bộ chấm tất định phán đúng–sai, mô hình người học là phép chiếu tái lập được từ sổ sự kiện, còn LLM chỉ diễn đạt phía sau một bộ kiểm chứng. Gia sư còn phải biết nội dung của giáo viên mà không dạy trước, nên chúng tôi dựng đồ thị tri thức từ 18 tệp tài liệu và truy xuất lai bị ràng buộc theo đồ thị. Ràng buộc làm Hit@3 tụt xuống $0{,}45$; một bước định tuyến chủ đề đưa nó lên $0{,}95$, ngang hoặc hơn một RAG phẳng, và loại việc đưa đoạn của bài sau vào câu trả lời ($0/30$ so với $12/30$ câu). Trên 13 vai học sinh khó, chatbot thường nói ra đáp án ở 18/25 lượt, lời nhắc Socratic soạn kỹ ở 1/25 và CAVAT ở 0/25. Phép chiếu hiểu bài khớp công thức đóng trên $1\,000$ chuỗi sự kiện và đáp ứng đầy đủ $16/25$ mục của khung đánh giá. Thực nghiệm dùng học sinh mô phỏng; các giới hạn được nêu rõ.

Từ khóa: gia sư thông minh; phương pháp Socratic; truy xuất tăng cường sinh văn bản; đồ thị tri thức; mô hình người học; tiếng Việt.

I. GIỚI THIỆU

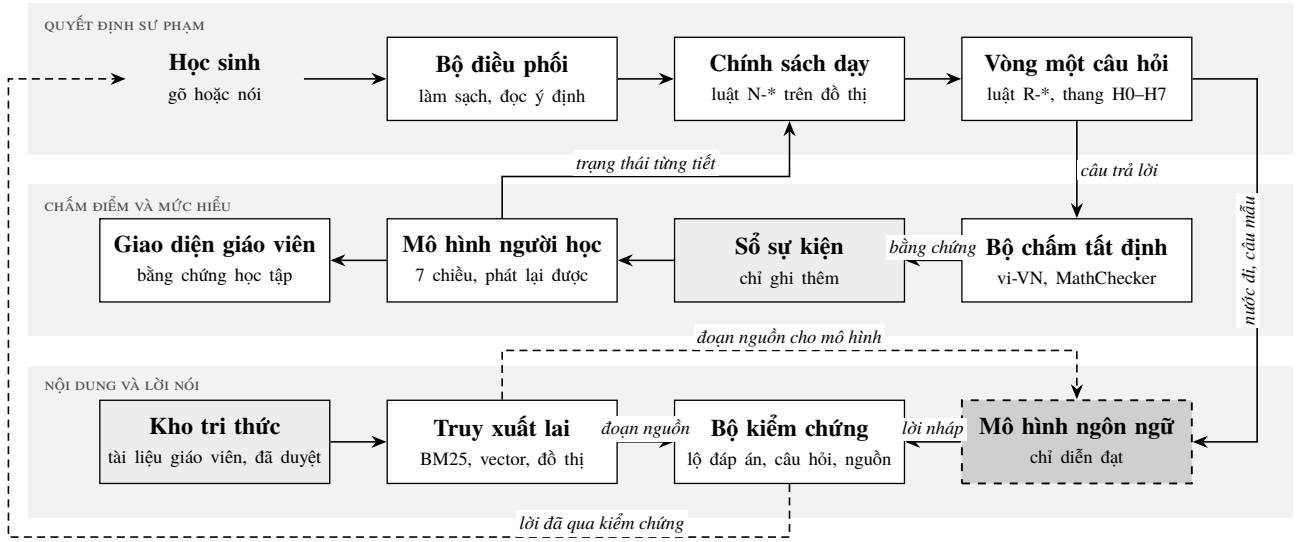
Dạy kèm từng học sinh là một trong những can thiệp giáo dục hiệu quả nhất được biết đến [1, 2]. Các mô hình ngôn ngữ lớn (LLM) hứa hẹn đưa lợi ích này đến nhiều trẻ hơn, nhưng cũng mang theo một rủi ro sư phạm đã được ghi nhận: mô hình có xu hướng đưa ngay đáp án hoặc làm hộ bài [3, 4], và học sinh dùng trợ lý không ràng buộc có thể làm bài tốt hơn lúc luyện tập nhưng kém đi khi kiểm tra [5]. Một gia sư thiết kế theo nguyên tắc sư phạm thì cho kết quả tốt [6]; vấn đề là làm sao để nguyên tắc ấy được giữ.

Các nhà cung cấp lớn trả lời bằng "chế độ học" [7, 8, 9], nhưng ràng buộc sư phạm chỉ tồn tại như lời khuyên trong ngữ cảnh: mô hình vẫn là nơi ra quyết định. Khi trẻ khăng khăng một đáp án sai, nhờ làm hộ, hoặc ra lệnh "bỏ qua mọi hướng dẫn" [10], không có cơ chế nào bảo đảm hành vi đúng.

Ý tưởng chính của bài báo là quyết định sư phạm (hỏi gì, gợi ý ở bậc nào, khi nào dừng) là một bài toán điều khiển có trạng thái, luật hóa được và kiểm chứng được; LLM chỉ cần ở khâu biến quyết định thành lời tự nhiên. Giả thuyết của chúng tôi: nếu quyết định, phán xét đúng–sai và mức hiểu bài do thành phần tất định đảm nhiệm thì tỉ lệ lượt lộ đáp án về 0 mà chất lượng lời nói vẫn chấp nhận được, và điều này đo được bằng luật.

Tách như vậy tạo ra một vấn đề thứ hai: gia sư phải dạy đúng nội dung của giáo viên mà không dạy trước điều học sinh chưa học. RAG thông thường không có khái niệm "chưa học", nên chúng tôi dựng nội dung thành đồ thị tri thức và dùng đồ thị làm ràng buộc phạm vi cho truy xuất. Ràng buộc này làm độ chính xác tụt, và một bước định tuyến chủ đề khôi phục nó. Đóng góp của bài báo:

1. Một kiến trúc gia sư trong đó chính sách tất định chọn nước đi, bộ chấm tất định quyết định đúng–sai, mức hiểu bài là phép chiếu tái lập được từ sổ sự kiện, và LLM chỉ diễn đạt sau một bộ kiểm chứng.
2. Một thiết kế truy xuất lai ràng buộc theo đồ thị tri thức, có định tuyến chủ đề, dựng từ tài liệu thật của giáo viên.
3. Một giao thức đánh giá nhiều chiều với tập kiểm tra đóng băng, so với RAG phẳng, chatbot thương mại và chính mô hình của hệ chỉ có lời nhắc.
4. Bằng chứng về độ sát khung đánh giá của mô hình người học: đối chiếu từng mục, tương đương công thức đóng và đường đáp ứng.



Hình 1. Kiến trúc của CAVAT. Mô hình ngôn ngữ (ô xám đậm, nét đứt) là thành phần duy nhất không tất định và chỉ diễn đạt; mọi quyết định sư phạm, phán quyết đúng–sai và điểm số đi qua thành phần tất định (ô trắng). Sổ sự kiện chỉ ghi thêm (ô xám nhạt) là nguồn sự thật duy nhất, mức hiểu bài tính lại được từ đó. Nét đứt: đoạn nguồn đi tới mô hình; lời chỉ đến học sinh sau bộ kiểm chứng.

II. CÔNG TRÌNH LIÊN QUAN

Gia sư thông minh và gia sư dùng LLM. Gia sư thông minh điều khiển *mức hỗ trợ*: giàn giáo giảm dần [11], "nghịch lý hỗ trợ" [12, 13] và hiệu ứng đảo ngược chuyên môn [14]; AutoTutor [15] tự động hóa hội thoại có cấu trúc. Các công trình này chọn mức hỗ trợ bằng luật, đúng điều CAVAT cần, nhưng hội thoại của chúng soạn sẵn nên hẹp. LearnLM-Tutor [16] và SocraticLM [17] huấn luyện hoặc nhắc LLM theo nguyên tắc sư phạm và mở rộng được hội thoại, song vẫn để mô hình ra quyết định; các phép đo cho thấy mô hình nền vẫn đưa đáp án hoặc nhận lỗi sai [3, 4]. CAVAT giữ luật của gia sư thông minh và dùng LLM chỉ để diễn đạt.

Truy xuất tăng cường. RAG [18] kết hợp BM25 [19], truy xuất vector [20] và hợp nhất hạng [21]; các hệ dùng đồ thị [22] khai thác cấu trúc để tổng hợp toàn cục. Chúng truy xuất tốt nhưng không có khái niệm "bài chưa học", thứ mà dạy học cần. CAVAT dùng đồ thị theo cách khác: như một *ràng buộc phạm vi chương trình*.

Mô hình người học và đánh giá. Vết kiến thức dùng xác suất [23, 24] hoặc mạng nơ-ron [25]; chúng dự đoán tốt nhưng khó giải thích cho giáo viên và không gắn với một khung đánh giá cho trước. CAVAT dùng bằng chứng Beta theo chiều để đối chiếu từng mục với khung. Giám khảo LLM [26] chỉ đánh giá chất lượng ngôn ngữ; các chỉ số còn lại đo bằng luật. So sánh dùng khoảng Wilson [27], bootstrap [28] và kiểm định McNemar [29].

III. PHƯƠNG PHÁP ĐỀ XUẤT

III.A Kiến trúc tổng thể

Hình 1 tóm tắt kiến trúc. Mỗi lượt, bộ điều phối làm sạch và đọc ý định lời học sinh; chính sách dạy trên đồ thị chọn tiết, vòng một câu hỏi chọn *nước đi* (nêu câu hỏi, gợi ý, hỏi lý do, phản ví dụ, kéo về, khép câu, giải thích) cùng bậc gợi ý; bộ chấm tất định quyết định đúng–sai; mô hình ngôn ngữ nhận nước đi, câu mẫu và đoạn nguồn rồi *diễn đạt*; bộ kiểm chứng chặn lời lộ đáp án, nhiều hơn một câu hỏi, quá dài, không có căn cứ hoặc không an toàn, và thay bằng câu mẫu của giáo viên. Sáu bất biến được thực thi trong mã và kiểm chứng ở Mục IV: (B1) đáp án của câu kiểm tra không bao giờ nằm trong ngữ cảnh của mô hình; (B2) chính sách quyết định nước đi, mô hình chỉ diễn đạt; (B3) đúng–sai do bộ chấm tất định; (B4) điểm là phép chiếu tái lập được từ sổ sự kiện; (B5) không dạy trước nội dung của tiết sau; (B6) mọi điều gia sư khẳng định có trong đoạn nguồn hoặc lời học sinh. Mọi ràng buộc phiên do máy chủ thực thi.

III.B Chính sách Socratic và thang gợi ý

Chính sách là tập luật tường minh có phiên bản. Trợ giúp được cho *vừa đủ*: thang gợi ý có tám bậc H_0–H_7 (không gợi ý, câu hỏi định hướng, nhắc khái niệm, gợi ý chiến lược, một bước trung gian, chia nhỏ bài, cùng làm từng bước, giải thích đầy đủ) với trọng số độc lập $\iota_h = 1{,}0;\ 0{,}85;\ 0{,}70;\ 0{,}60;\ 0{,}50;\ 0{,}35;\ 0{,}20;\ 0$. Học sinh bắt đầu ở bậc nhẹ nhất; mỗi lần chưa giải được tăng một bậc; trợ giúp rút lại khi học sinh làm được một bước. Chỉ H_7 được nói ra đáp án và chỉ ở hoạt động luyện tập; trong kiểm tra, một luật chặn ở H_1. Những lượt không phải một lần thử ("là sao ạ", lạc đề, "chán quá") không bị tính là sai. Quyết định là hàm tất định của trạng thái, nên cùng một buổi học luôn phát lại cho cùng kết quả.

III.C Truy xuất lai ràng buộc theo đồ thị tri thức

Đồ thị $G = (V, E)$ có đỉnh là tiết học và cạnh PREREQUISITE, APPLICATION. Mỗi đoạn c gắn với một tiết $\nu(c)$. Với câu hỏi q khi đang học tiết v, phạm vi gồm tiết v và tiên quyết trong hai bước; đoạn của tiết chưa học bị loại. Chỉ mục kết hợp BM25 trên âm tiết và cặp âm tiết liền kề với vector 768 chiều (`gemini-embedding-001`), hợp nhất bằng RRF có trọng số khoảng cách trên đồ thị d_G:

$$\text{fuse}(c) = \frac{1}{1 + d_G(v, \nu(c))} \sum_{r \in \{\text{BM25},\, \cos\}} \frac{1}{60 + \text{rank}_r(c)}, \tag{1}$$

rồi xếp hạng lại theo sư phạm: $\text{score}(c) = \text{fuse}(c)\, \kappa_m(\text{loại}_c)\, \gamma(c)$, với κ_m ưu tiên lời giảng khi dạy, ví dụ mẫu khi neo gợi ý, định nghĩa khi hỏi "X là gì", và γ giảm đoạn đã dùng, tăng đoạn đúng lỗi quan niệm

Bảng 1. Dữ liệu đánh giá. Tập giữ riêng không dùng để chỉnh gì.

Tập	Cỡ	Dùng cho
Truy xuất, bộ chỉnh	30 câu	chỉnh ngưỡng
Truy xuất, giữ riêng v1	23 câu	chỉ đo (đã thấy)
Truy xuất, giữ riêng v2	30 câu	đóng băng trước DI-57
Vai học sinh khó	25 lượt	hành vi
Chấm đáp án v1 / v2	36 / 35 câu	độ tin cậy chấm
Chuỗi sự kiện	2×500	tương đương công thức
Khung đánh giá	25 mục	độ sát khung

vừa gặp. *Định tuyến*: phạm vi chặt có một cái giá, vì câu hỏi về một chủ đề của tiết trước bị đẩy xuống bởi trọng số $1/(1+d_G)$. Mỗi tiết trong phạm vi được chấm bằng cosine lớn nhất của các đoạn của nó; nếu một tiết đã học $u^\star$ gần câu hỏi hơn tiết đang học ít nhất $\varepsilon = 0{,}02$ thì câu được coi là nói về $u^\star$ và các đoạn của $u^\star$ nhận $d_G = 0$. Định tuyến chỉ xét tiết trong tổ tiên, không bao giờ một tiết sau, nên B5 vẫn giữ. Khi cosine lớn nhất của các đoạn được chọn nhỏ hơn $0{,}65$, câu hỏi được giữ cho giáo viên thay vì được trả lời bằng điều bịa.

III.D Mô hình người học tái lập được

Mỗi tiết v có bằng chứng $\mathrm{Beta}(\alpha_{v,d}, \beta_{v,d})$ theo bảy chiều $d \in \{C, R, A, T, I, S, D\}$ (đúng, lập luận, vận dụng, chuyển giao, độc lập, ghi nhớ, chẩn đoán lỗi). Mỗi sự kiện cập nhật $\alpha \leftarrow \alpha + ws$, $\beta \leftarrow \beta + w(1-s)$ với điểm s và trọng số w phụ thuộc độ khó, bậc gợi ý ι_h và hoạt động. Mức hiểu là tổng có trọng số trên các chiều có bằng chứng (tái chuẩn hóa khi thiếu chiều):

$$M_v = 100 \cdot \frac{\sum_{d \in \mathcal{A}_v} \omega_d \, \mu_{v,d}}{\sum_{d \in \mathcal{A}_v} \omega_d}, \tag{2}$$

với $\omega = (0{,}20; 0{,}20; 0{,}15; 0{,}15; 0{,}10; 0{,}10; 0{,}10)$ cho (C, R, A, T, I, S, D), cùng độ tin cậy và các cổng chặn (giải thích, vận dụng, độc lập). Mô hình ngôn ngữ không bao giờ ghi điểm: M_v là phép chiếu có phiên bản của sổ sự kiện chỉ ghi thêm, nên phát lại cho kết quả giống hệt.

IV. THỰC NGHIỆM VÀ KẾT QUẢ

IV.A Thiết lập

Dữ liệu. Hai chương Toán lớp 5 ("Số thập phân", "Diện tích hình tam giác, hình thang") dựng từ 18 tệp tài liệu thật của giáo viên (77 trang): đồ thị 19 tiết, 389 câu hỏi có đáp án (349 câu được kiểm chính xác không dùng mô hình) và 221 đoạn truy xuất. Các tập đánh giá nêu ở Bảng 1; mọi tập giữ riêng được viết sau khi chỉnh tham số và đóng băng bằng thẻ git *trước* khi sửa mã.

Hệ so sánh. Mỗi phép so đổi đúng một thứ. B1 là đối chứng đơn giản nhất: chatbot Gemini Flash với lời nhắc thường, không phải một chế độ học thương mại. B2 dùng cùng mô hình Qwen của CAVAT với một lời nhắc Socratic soạn kỹ; B2 và CAVAT (C) chỉ khác nhau ở chính sách và bộ kiểm chứng. Với truy xuất, các cấu hình từ khóa, ngữ nghĩa, lai, có và không xếp hạng lại là các bước thêm từng thành phần; RAG phẳng giống CAVAT trừ ràng buộc đồ thị. **Chỉ số.** Hit@k, MRR; tỉ lệ lộ đáp án theo luật tất định; số câu hỏi mỗi lượt; độ dài; đúng–sai của bộ chấm; giám khảo `gpt-oss-120b` (khác họ với gia sư) chấm giọng Socratic và độ phù hợp trẻ; khoảng Wilson 95%, bootstrap theo cặp (10 000 lần) và kiểm định McNemar chính xác.

IV.B So sánh truy xuất với RAG phẳng

Bảng 3 và Hình 2 so CAVAT với RAG phẳng. Về độ chính xác, CAVAT ngang hoặc hơn (trên tập giữ riêng v2: Hit@3 0,95 so với 0,90, MRR 0,954 so với 0,839). Khác biệt nằm ở *dạy trước*: RAG phẳng đưa đoạn của bài sau vào top-3 ở $12/30$ câu và trả lời cả $4/4$ câu hỏi về bài sau, còn CAVAT là $0/30$ và $0/4$. Ràng buộc phạm vi tự nó làm giảm độ chính xác khi chưa định tuyến (Hit@3 trên tập v2: $0{,}45$); định tuyến khôi phục lên $0{,}90$ (McNemar chính xác $p = 0{,}004$, 9 câu được cứu và 0 câu hỏng). Cái được của đồ thị vì vậy là *an toàn phạm vi*, không phải độ chính xác. So với bảy định hướng đặt ra lúc thiết kế (Bảng 2), truy xuất đạt trung bình 85%; chỉ R7 (lai cộng xếp hạng lại là tốt nhất trên mọi tập) không đạt, do chương mẫu.

IV.C Hành vi Socratic so với chatbot thương mại

Bảng 4 và Hình 3 đối chiếu ba hệ trên cùng chuỗi lời nói của 13 vai học sinh khó (không biết, đòi đáp án, "bỏ qua hướng dẫn", lạc đề, sai mà chắc...). Chatbot thường (B1) nói ra đáp án ở 18/25 lượt (72%; luật kiểm cả câu trắc nghiệm), 80% lượt dài quá 60 từ. Lời nhắc Socratic (B2) giảm còn 1/25 (4%); CAVAT là 0/25 (15 lượt do Qwen viết, 10 lượt là câu mẫu). Trong 468 lượt của gia sư ở các buổi học mô phỏng, kiểm tra tất định trên 308 lượt có đáp án để lộ không thấy lượt nào lộ ($0/308$). Điều CAVAT *không* thắng: giám khảo chấm B2 cao hơn về giọng Socratic ($4{,}84$ so với 4,68) và không thấy lượt lộ đáp án duy nhất của B2 (luật tất định thấy, giám khảo thì không); giá trị của CAVAT nằm ở các bảo đảm, không ở sự tự nhiên.

Về chấm đáp án gán nhãn tay của trẻ, bộ chấm tất định của CAVAT cho 0 sai dương và 0 sai âm trên tập giữ riêng v2 ($35/35$; v1: $36/36$); chatbot thường chấm sai 10 câu đúng ($25/35$; v1: $25/36$), thường vì cách viết số của trẻ; cùng mô hình với lời nhắc Socratic đạt $35/35$ trên v2.

IV.D Độ sát khung đánh giá của mô hình người học

Chúng tôi đo "sát khung" ở bốn nghĩa. *Nội dung*: trong 25 mục của khung đánh giá Toán của dự án, 16 mục được làm đầy đủ, 5 một phần và 4 chưa làm (74% khi một phần tính một nửa). *Tính toán*: so mã với công thức đóng trên 2×500 chuỗi sự kiện ngẫu nhiên: chênh lệch lớn nhất $0{,}050$ (làm tròn), không chuỗi nào khác công thức, đổi thứ tự sự kiện không đổi M, phát lại cho kết quả giống hệt. *Hành vi*: M tăng khi tăng câu đúng liên tiếp và giảm khi cần gợi ý cao hơn (Hình 5) và bản đồ nhiệt cho giáo viên (Hình 4) hiển thị từng chiều có bằng chứng; học sinh dựng sẵn "giỏi", "hay sai" và "phụ thuộc" được xếp đúng thứ tự mong đợi. *Độ bền*: kết luận về học sinh ổn định khi đổi một diễn giải khai báo sang giá trị lân cận, trừ ngưỡng giải thích.

IV.E Nghiên cứu loại bỏ thành phần (Ablation Studies)

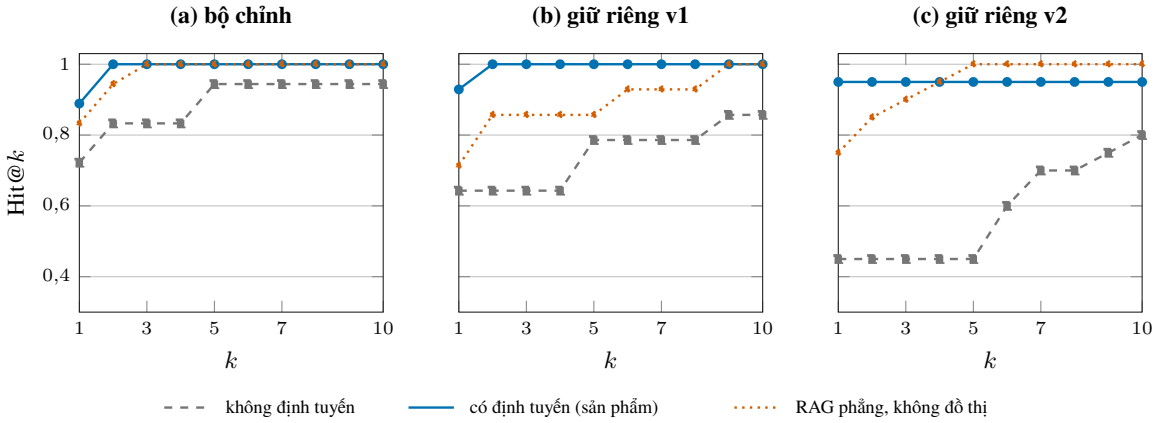
Bảng 5 bỏ từng thành phần của kiến trúc. Hai thành phần quyết định hành vi sư phạm tác động rõ nhất: bỏ chính sách và bộ kiểm chứng làm lượt nói ra đáp án tăng từ 0 lên 1/25 với cùng mô hình (B2; chênh lệch này không có ý nghĩa thống kê ở cỡ mẫu này), còn chatbot thường (B1, khác cả mô hình) là 18/25; bỏ bộ kiểm chứng thì 5 lời nháp có lỗi trong 21 ca lời nói có căn cứ đến thẳng trẻ (một trong số đó là câu đúng về Toán bị chặn vì dùng đơn vị không có trong đoạn nguồn); về chấm đáp án, cùng mô hình chấm bằng lời nhắc cũng đúng $35/35$, nên cái bộ chấm tất định mua được là tính

Bảng 2. Mức đạt so với bảy định hướng thiết kế của truy xuất. Mức đạt $= \min(1, \text{đo được}/\text{mục tiêu})$.

Mã	Định hướng	Mục tiêu	Đo được	Mức đạt
R1	Truy xuất đúng đoạn cho câu hỏi trong bài (Hit@3)	$\geq 0{,}90$	0,87	96%
R2	Câu lạc đề, Toán ngoài chương không được trả lời	$\geq 95\%$	100%	100%
R3	Câu trong chương được nhận là có căn cứ và trả lời	$\geq 95\%$	95%	100%
R4	Không dạy trước nội dung bài sau	100%	100%	100%
R5	Lời trả lời bám nguồn (giám khảo, thang 5)	$\geq 95\%$	100%	100%
R6	Lượt bịa hoặc lộ đáp án	$\leq 2\%$	0%	100%
R7	Lai + xếp hạng lại tốt nhất trong các thành phần (MRR)	có/không	không	0%
Mức đạt trung bình của bảy định hướng				**85%**

Bảng 3. CAVAT (đồ thị) so với RAG phẳng. "Đoạn bài sau": số câu có đoạn của tiết chưa học trong top-3.

Tập	Hệ truy xuất	Hit@3	MRR	Đoạn bài sau trong top-3	Câu bài sau bị trả lời	Câu ngoài chương bị trả lời
Bộ chỉnh	CAVAT (đồ thị)	1,00	0,944	0/30	0/4	0/8
	RAG phẳng	1,00	0,907	10/30	4/4	1/8
	RAG phẳng + xếp hạng lại	1,00	0,880	12/30	4/4	1/8
Giữ riêng v1	CAVAT (đồ thị)	1,00	0,964	0/23	0/3	0/6
	RAG phẳng	0,86	0,806	9/23	3/3	1/6
	RAG phẳng + xếp hạng lại	0,86	0,789	9/23	3/3	1/6
Giữ riêng v2	CAVAT (đồ thị)	0,95	0,954	0/30	0/4	0/6
	RAG phẳng	0,90	0,839	12/30	4/4	1/6
	RAG phẳng + xếp hạng lại	0,90	0,839	11/30	4/4	1/6



Hình 2. Hit@k của cấu hình sản phẩm khi không và có định tuyến, cùng RAG phẳng, trên ba tập của chương phát hành.

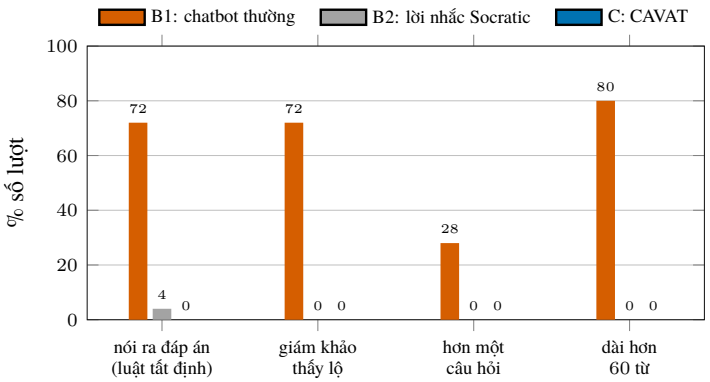
tất định và kiểm toán được, còn B1 bác $10/35$ đáp án đúng. Với truy xuất, ràng buộc phạm vi là thành phần duy nhất ngăn dạy trước ($0/30$ so với $12/30$); định tuyến khôi phục độ chính xác mà ràng buộc làm mất ($0{,}45 \rightarrow 0{,}95$ Hit@3); cờ xếp hạng lại cũ bật cả định tuyến và ưu tiên định nghĩa (DI-50); đo tách từng thành phần (RAG-5), trong mức tăng MRR $0{,}460 \rightarrow 0{,}954$ trên v2 các hệ số xếp hạng lại góp $0{,}000$ (bỏ chúng không đổi hạng câu nào) và toàn bộ phần tăng là định tuyến (bỏ nó: $-0{,}450$, KTC $[-0{,}642;\ -0{,}263]$); ưu tiên định nghĩa có hai lỗi (bỏ tên hình được hỏi, nhận nhầm khái niệm giữa câu), đã sửa (RAG-6). Trên tập v3 viết như trẻ gõ (không dấu, viết tắt; 30 câu, đóng băng trước khi sửa), CAVAT đạt Hit@3 $0{,}80$, MRR $0{,}822$; định tuyến cứu 8 câu ($p = 0{,}008$); RAG phẳng truy xuất ngang ($0{,}832$) nhưng dạy trước ở $13/43$ câu. Sửa từ các câu trượt đó (RAG-7: định tuyến cả khi tiết trước gần hơn dưới lề mà từ khóa không kém; câu nêu thuật ngữ Toán không có trong kho là ngoài chương) và đo trên tập v4 đóng băng trước: MRR $0{,}897 \rightarrow 0{,}935$, nhưng $2/8$ câu Toán ngoài chương dùng chung từ với chương vẫn lọt cổng. Đáng chú ý, vector ngữ nghĩa trong cấu hình lai không cải thiện đáng kể so với từ khóa khi chưa xếp hạng lại ($0{,}459$, $0{,}449$, $0{,}460$, khoảng tin cậy chồng nhau), và đóng góp của xếp hạng lại *không* chuyển sang chương mẫu (cỡ 15; $0{,}722 \rightarrow 0{,}678$): định hướng R7 không đạt. Hình 6 cho thấy MRR theo lề ε; giá trị sản phẩm $0{,}02$ nằm ở vùng ổn định, và tắt hẳn định tuyến làm MRR rơi về $0{,}503$.

IV.F Phân tích lỗi và giới hạn của chứng cứ

Truy xuất. Trên tập giữ riêng v2, hệ sản phẩm sai ở 3 trong 30 câu. Hai câu ("phần thập phân nằm ở bên nào dấu phẩy" và "làm tròn đến hàng phần mười là nhìn chữ số nào") truy xuất một đoạn nói đúng điều cần, nhưng ở tiết khác với nhãn (hạng 14 và 6 của đoạn được gán nhãn, cosine $0{,}77$ và $0{,}80$);

Bảng 4. Ba hệ trên 13 vai học sinh khó. “Nói ra đáp án”: theo luật tất định. Điểm giám khảo: thang 1–5.

Chỉ số (13 vai, 25 lượt)	B1	B2	C (CAVAT)
Số lượt gia sư được chấm	25	25	25
Nói ra đáp án (luật tất định)	18	1	0
Giám khảo thấy lộ đáp án	18	0	0
Lượt có hơn một câu hỏi	7	0	0
Lượt dài hơn 60 từ	20	0	0
Số từ trung bình mỗi lượt	128	29	24
Khen một đáp án sai là đúng (trong 4 lượt sai)	1	1	0
Giám khảo: đáp đúng ý của con	3,08	4,88	4,88
Giám khảo: theo phương pháp Socratic	2,28	4,84	4,68
Giám khảo: hợp với trẻ 10 tuổi	4,20	4,88	4,92
Giám khảo: bám bài đang làm	4,76	4,92	4,88



Hình 3. Tỉ lệ số lượt vi phạm theo bốn phép đo, cho ba hệ.

Số thập phân

	C	R	A	T	I	S	D	M	tin cậy	mức hiểu
T01	87	58	–	–	82	–	–	**74**	35	Quy trình, đã qua
T02	93	72	–	–	82	–	–	**83**	19	Khái niệm, đã qua
T03	84	73	–	–	96	–	–	**82**	39	Khái niệm, đã qua
T04	93	69	–	–	89	–	–	**83**	22	Khái niệm, đã qua
T05	95	60	90	–	76	–	–	**81**	46	Vận dụng, đã qua
T06	97	78	–	–	91	–	–	**88**	28	Khái niệm, đã qua
T07	94	89	–	–	86	–	–	**90**	21	Khái niệm, đã qua
T08	95	67	–	–	93	–	–	**83**	20	Vận dụng, đã qua
T09	96	85	–	–	88	–	–	**90**	20	Khái niệm, đã qua
T10	95	90	94	–	90	–	–	**92**	27	Vận dụng, đã qua
T11	93	89	90	–	89	–	–	**91**	31	Vận dụng, đã qua

0–39 40–59 60–74 75–89 90–100 chưa đủ bằng chứng

Hình 4. Bản đồ nhiệt của học sinh mô phỏng S1 ở chương Số thập phân (giao diện giáo viên): hàng là tiết, cột là bảy chiều, “tin cậy” là độ tin cậy của M; màu là vùng của khung đánh giá, số là phần nguyên của điểm; “–” là chiều chưa có bằng chứng.

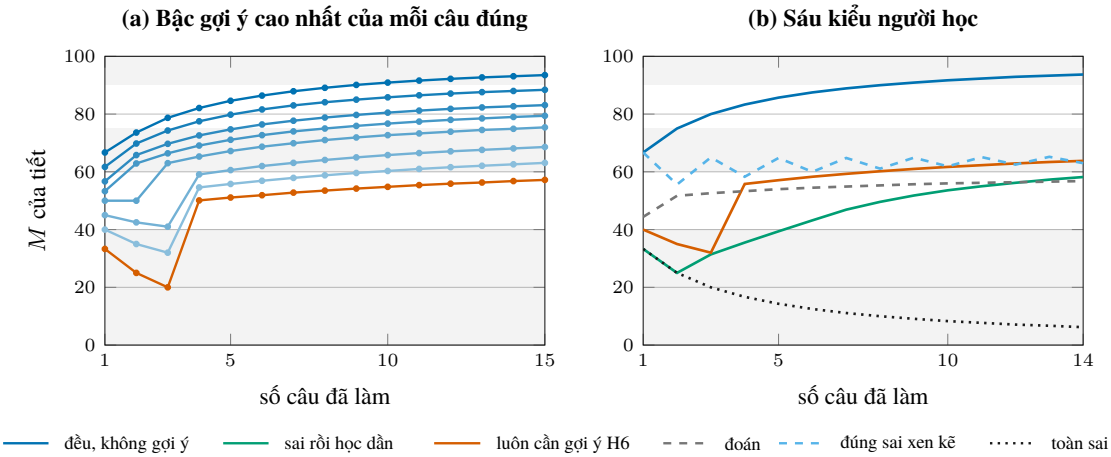
nhãn chặt hơn điều một học sinh cần, nên đây là chặn trên của lỗi. Câu còn lại là lỗi thật: “số 7,25 đọc như thế nào ạ” bị báo “bài sau” vì một đoạn của tiết so sánh gần câu hơn đoạn của tiết đang học 0,03. Hệ chọn sai về phía thận trọng, nhưng một đứa trẻ bị bảo chờ một điều thuộc bài mình đang học.

Lời của mô hình. Trong 468 lượt của học sinh mô phỏng S1, 397 lượt (85%) là câu mẫu của giáo viên, mô hình chỉ viết 4 lượt; 16 lần chặn là lần kiểm cuối chặn cả câu mẫu dài với trần 60 từ, đã sửa sau đợt đo (DI-60). Con số $0/308$ lượt lộ đáp án vì vậy nói về chính sách và nội dung đã duyệt, không về văn của mô hình; phần lời do mô hình viết được đo riêng trên 13 vai ở Mục IV.C.

Giới hạn khác. Học sinh là mô phỏng nên các kết luận về hiệu quả học tập chưa có; giám khảo là một LLM nên điểm giọng nói có sai số; nhãn truy xuất do một trợ lý AI soạn và chưa có giáo viên duyệt.

V. KẾT LUẬN

CAVAT cho thấy một điều hẹp nhưng kiểm chứng được: khi quyết định sư phạm, phán xét đúng–sai và mức hiểu bài thuộc về thành phần tất định, lượt lộ đáp án trong các tình huống thử thách giảm từ 18/25 (chatbot thường) và 1/25 (lời nhắc Socratic soạn kỹ) xuống 0/25; chênh lệch giữa hai hệ sau không có ý nghĩa thống kê ở cỡ mẫu này. Truy xuất theo đồ thị loại việc dạy trước mà RAG phẳng mắc ở $12/30$ câu, với



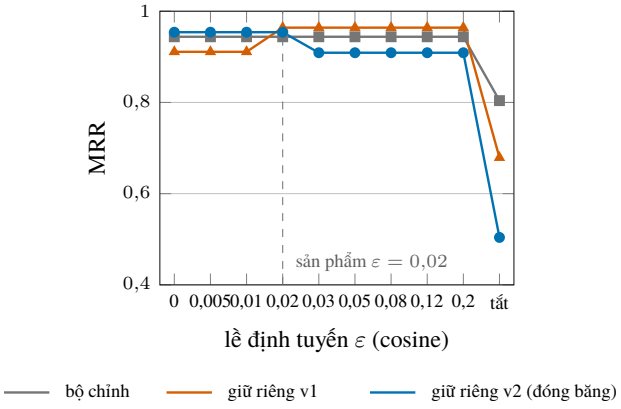
Hình 5. Đường đáp ứng của M (một tiết không tiên quyết). (a) n câu đúng liên tiếp theo bậc gợi ý cao nhất h. (b) Sáu kiểu học sinh dựng sẵn.

Bảng 5. Ablation theo thành phần của kiến trúc: bỏ một thành phần (hoặc thay bằng đối chứng) thì chỉ số bảo đảm tương ứng đổi ra sao. Số liệu lấy từ các thí nghiệm ở Mục IV; "Có" là CAVAT đầy đủ.

Thành phần bỏ đi	Thay bằng	Chỉ số (thấp hơn là tốt)	Có	Không
Chính sách và bộ kiểm chứng	lời nhắc Socratic cùng mô hình (B2)	lượt nói ra đáp án	0/25	1/25
	đối chứng khác cả mô hình (B1)	lượt nói ra đáp án	0/25	18/25
Bộ kiểm chứng riêng	gửi thẳng lời nháp của mô hình	lời nháp có lỗi đến trẻ (21 ca lời nói có căn cứ)	0	5
Bộ chấm tất định	mô hình tự chấm: cùng mô hình (B2); B1	đáp án đúng bị chấm sai (v2)	0/35	0/35; 10/35
Ràng buộc phạm vi theo đồ thị	RAG phẳng	câu có đoạn của bài sau trong top-3 (v2)	0/30	12/30
Định tuyến chủ đề	tắt ($\varepsilon = \infty$)	$1 - \text{Hit@3}$ (v2)	0,10	0,55
Xếp hạng lại sư phạm	bỏ khỏi cấu hình đủ	$1 - \text{MRR}$ (v2)	0,046	0,046
Ưu tiên đoạn định nghĩa (DI-50)	bỏ khỏi cấu hình đủ	$1 - \text{MRR}$ (v4)	0,065	0,065
Vector ngữ nghĩa	chỉ từ khóa (cả hai có xếp hạng lại)	$1 - \text{MRR}$ (v2; $p = 0{,}125$)	0,046	0,270

Bảng 6. Ablation của truy xuất trên tập giữ riêng v2 ($n = 20$). KTC: khoảng tin cậy 95% bootstrap. Hai dòng cuối: RAG phẳng.

Cấu hình	Hit@1	Hit@3	MRR	KTC 95%
Từ khóa	0,40	0,40	0,459	[0,26; 0,65]
Ngữ nghĩa	0,40	0,40	0,449	[0,25; 0,64]
Lai	0,40	0,40	0,460	[0,26; 0,65]
Từ khóa + xếp hạng lại	0,70	0,70	0,729	[0,54; 0,91]
Lai + xếp hạng lại	0,95	0,95	**0,954**	[0,86; 1,00]
Lai phẳng	0,75	0,90	0,839	[0,71; 0,95]
Lai phẳng + xếp hạng lại	0,75	0,90	0,839	[0,71; 0,95]



Hình 6. MRR theo lề định tuyến ε; điểm cuối là tắt định tuyến. Đường đứt: giá trị sản phẩm.

độ chính xác ngang hoặc hơn sau khi định tuyến; truy xuất đạt trung bình 85% so với bảy định hướng thiết kế. Phép chiếu hiểu bài tái lập được và khớp công thức đóng.

Cái giá cũng rõ: giám khảo chấm giọng của lời nhắc Socratic soạn kỹ tự nhiên hơn (4,84 so với 4,68), và giá trị của CAVAT nằm ở các bảo đảm chứ không ở sự tự nhiên của lời nói.

Hạn chế và hướng tiếp theo. Kết quả ở hai chương của một môn, một giáo viên, tiếng Việt, với học sinh mô phỏng và nhãn do một người gán; tập giữ riêng nhỏ (14–57 câu) nên khoảng tin cậy rộng. Độ trễ, chi phí mỗi lượt và hiệu quả học tập trên học sinh thật chưa được đo. Ba bước tiếp theo: thử nghiệm có đối chứng với học sinh thật cùng kiểm tra trì hoãn sau 7 và 30 ngày (để đo chiều ghi nhớ S hiện bỏ trống); nhãn của giáo viên cho truy xuất và lỗi quan niệm; và mở rộng sang chương, lớp, môn khác để kiểm tra điều gì mang tính tổng quát.

TÀI LIỆU THAM KHẢO

[1] B. S. Bloom. The 2 sigma problem: The search for methods of group instruction as effective as one-to-one tutoring. *Educational Researcher*, 13(6):4–16, 1984.

[2] K. VanLehn. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4):197–221, 2011.

[3] J. Macina, N. Daheim, S. Pal Chowdhury, T. Sinha, M. Kapur, I. Gurevych, M. Sachan. MathDial: A dialogue tutoring dataset with rich pedagogical properties grounded in math reasoning problems. *Findings of EMNLP*, 2023.

[4] A. Tack, C. Piech. The AI Teacher Test: Measuring the pedagogical ability of Blenderbot and GPT-3 in educational dialogues. *Proceedings of the 15th International Conference on Educational Data Mining*, 2022.

[5] H. Bastani, O. Bastani, A. Sungu, H. Ge, Ö. Kabakcı, R. Mariman. Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, 122(26), 2025.

[6] G. Kestin, K. Miller, A. Klales, T. Milbourne, G. Ponti. AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, 15, 2025.

[7] OpenAI. Study mode trong ChatGPT, ra mắt tháng 7/2025. Tổng hợp tại `https://www.maginative.com/article/openai-launches-study-mode-for-chatgpt/`.

[8] Google. Guided Learning trong ứng dụng Gemini, ra mắt tháng 8/2025. `https://9to5google.com/2025/08/06/gemini-guided-learning/`.

[9] Khan Academy. Khanmigo. Nghiên cứu tình huống tại `https://cut-the-saas.com/ai/how-khan-academy-leveraged-ai-to-change-education`.

[10] F. Perez, I. Ribeiro. Ignore previous prompt: Attack techniques for language models. *NeurIPS ML Safety Workshop*, 2022.

[11] D. Wood, J. S. Bruner, G. Ross. The role of tutoring in problem solving. *Journal of Child Psychology and Psychiatry*, 17(2):89–100, 1976.

[12] K. R. Koedinger, V. Aleven. Exploring the assistance dilemma in experiments with cognitive tutors. *Educational Psychology Review*, 19(3):239–264, 2007.

[13] V. Aleven, I. Roll, B. M. McLaren, K. R. Koedinger. Help helps, but only so much: Research on help seeking with intelligent tutoring systems. *International Journal of Artificial Intelligence in Education*, 26:205–223, 2016.

[14] S. Kalyuga, P. Ayres, P. Chandler, J. Sweller. The expertise reversal effect. *Educational Psychologist*, 38(1):23–31, 2003.

[15] A. C. Graesser, P. Chipman, B. C. Haynes, A. Olney. AutoTutor: An intelligent tutoring system with mixed-initiative dialogue. *IEEE Transactions on Education*, 48(4):612–618, 2005.

[16] I. Jurenka và cộng sự. Towards responsible development of generative AI for education: An evaluation-driven approach. *arXiv:2407.12687*, 2024.

[17] J. Liu và cộng sự. SocraticLM: Exploring Socratic personalized teaching with large language models. *Advances in Neural Information Processing Systems*, 2024.

[18] P. Lewis và cộng sự. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 2020.

[19] S. Robertson, H. Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.

[20] V. Karpukhin và cộng sự. Dense passage retrieval for open-domain question answering. *Proceedings of EMNLP*, 2020.

[21] G. V. Cormack, C. L. A. Clarke, S. Büttcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. *Proceedings of SIGIR*, 2009.

[22] D. Edge và cộng sự. From local to global: A graph RAG approach to query-focused summarization. *arXiv:2404.16130*, 2024.

[23] A. T. Corbett, J. R. Anderson. Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4(4):253–278, 1995.

[24] R. Pelánek. Bayesian knowledge tracing, logistic models, and beyond: an overview of learner modeling techniques. *User Modeling and User-Adapted Interaction*, 27(3–5):313–350, 2017.

[25] C. Piech và cộng sự. Deep knowledge tracing. *Advances in Neural Information Processing Systems*, 2015.

[26] L. Zheng và cộng sự. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *NeurIPS Datasets and Benchmarks*, 2023.

[27] E. B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.

[28] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[29] Q. McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.